



AI OBSERVATORY

Osservare l'AI

**per migliorare la qualità delle risposte
e abbassare il costo dei modelli**

Un caso reale di chatbot · telemetria · latenza · token · costo

Andrea Tosato

60 minuti · talk + demo LIVE

La risposta è solo la punta dell'iceberg

Sotto il testo ci sono decisioni, tool, retry, token e denaro.



QUALITÀ

Fatti corretti?
Policy rispettate?
Fonti verificabili?



LATENZA

Quanto attendo?
Dove attendo?
È variabilità o regressione?



TOKEN

Input utile?
Cache hit?
Output o reasoning?



COSTO

Per chiamata?
Per run?
Per esito corretto?

Ottimizzare una sola metrica può peggiorare il sistema.

Dalla sensazione a una rubrica verificabile

La telemetria spiega il percorso; la rubrica valuta l'esito.

✓	Fatti	data consegna, stato, prezzo pagato
✓	Policy	14 giorni vs difetto entro 60
✓	Contesto	correzione del motivo del reso
✓	Grounding	prodotti reali, ID e prezzi
✓	Consenso	nessuna azione senza conferma

SCENARIO DI CORREZIONE

Il caso ORD-1042

Listino: 29,99 USD
Pagato: 19,99 USD
Consegna: 5 settembre 2026
Articolo outlet


Il cliente prima parla di ripensamento, poi chiarisce che il prodotto era difettoso.

QUALITÀ ≠ STILE

TOKEN ≠ QUALITÀ

Seguiamo ogni richiesta end-to-end

Inline, Skills e A2A condividono dominio e dati, ma non lo stesso percorso.



Una delega, un retry o una history diversa cambiano il numero di inferenze.

5.4 → 5.6 → 6: cambia il contratto, non solo il nome

Le guide evolvono da controllo della forma a obiettivi, prove e autonomia.

Forma e dettaglio

GPT-5.4

Guida la verbosità

Separa dettaglio da reasoning

Adatta la risposta al task

Esito e prove

GPT-5.6

Dichiara risultato e vincoli

Chiedi evidenze e stop condition

Rimuovi ridondanza per gruppi

Autonomia governata

GPT-6

Dichiara margine di autonomia

Chiarisci quando chiedere

Controlla skill e priorità

Non migrare i prompt con “trova e sostituisci”: rivaluta istruzioni, tool e criteri di completamento.

Fonti: guide ufficiali OpenAI GPT-5.4, GPT-5.6 Sol e GPT-6, verificate il 24–25/09/2026.

Astra, Sol, Luna... e Terra?

Stessa famiglia non significa stesso profilo operativo.

Massima capacità ASTRA Lavoro end-to-end difficile reasoning, coding, ricerca Tariffe listino: \$10 / \$1 / \$50 INPUT / CACHE / OUTPUT	Agentic & coding SOL Workflow complessi strumenti e contesto lungo Tariffe listino: \$2 / \$0,2 / \$10 INPUT / CACHE / OUTPUT	Efficienza LUNA Task focalizzati alto volume Tariffe listino: \$0,1 / \$0,01 / \$0,5 INPUT / CACHE / OUTPUT	Non verificato TERRA Nessuna model card ufficiale reperita al 25/09/2026 Tariffe listino: NON ASSUMERE VERIFICA PRIMA
---	---	---	---

Scegli per task + SLA + qualità accettabile. Non dal prezzo per token isolato.

Listino OpenAI Standard per 1M token, 25/09/2026. Cache write esclusa dalla terna. Oltre 272K input: tier maggiorato. Verificare sempre Azure/deployment.

Un prompt utile è un contratto osservabile

Riduci ambiguità prima di ridurre token.



RISULTATO

Cosa deve essere vero alla fine?



CONTESTO

Quali fatti servono davvero?



VINCOLI

Policy, sicurezza, consenso,
budget




PROVE

Fonti, tool, dati da citare



STOP

Quando completare o chiedere
chiarimenti



FORMATO

Struttura e livello di dettaglio

Tagliare prima di chiarire = risparmiare token per ottenere più retry.

Input, cache e output non costano allo stesso modo

Il ledger deve conservare contatori e tariffa applicata per ogni chiamata.



istruzioni dinamiche · history · tool result

prefisso stabile riusato

prefisso scritto

risposta + reasoning incluso

Cache hit

Riduce il costo del prefisso già noto. Non riduce automaticamente output, tool o retry.

Cache write


Può avere una tariffa propria. Nel ledger Sol sostituisce il normale costo input.

Reasoning

È un sottoinsieme dell’output: non sommarlo una seconda volta.

La cache premia la stabilità del prefisso

Metti il contenuto stabile prima; sposta il dinamico dopo.



Il costo corretto è una formula per chiamata

Poi si aggrega per run, conversazione ed esito.

$$((\text{nuovo input} \times R_i) + (\text{cached} \times R_c) + (\text{write} \times R_w) + (\text{output} \times R_o)) / 1.000.000$$

CHIAMATA

Quanto costa questa inferenza?

RUN

Tool + retry + deleghe?

CONVERSAZIONE

Quanto costa il percorso completo?


ESITO

Quanto costa una risposta corretta?

Costo assente = sconosciuto, non zero.

Prompt lungo: costo certo, latenza da misurare

La durata end-to-end è composta da più segmenti.



tempo end-to-end

Più contesto

+ prefill · + costo
ma meno lookup mancanti?

Più spiegazione

+ output · + tempo
ma più chiarezza?

Più autonomia

+ tool/retry possibili
ma meno handoff umano?

Nella demo la “prima risposta” è bufferizzata: non chiamarla TTFT del provider.

Cambiare una variabile. Ripetere. Conservare evidenza.

BAD vs GOOD, GOOD vs ridondante, GPT-5 vs GPT-6 Sol.



ORD-1042: osserviamo una correzione in tempo reale

La chat è l'inizio. Traccia, Inspector e ledger sono la prova.

1 Dov'è il mio ordine ORD-1042?

2 Posso restituirlo? Non l'ho usato.

3 **Correggo: era difettoso al primo utilizzo.**

4 Consigliami una camicia sotto i 40 \$.

LIVE

Consenso manuale · budget 0,10 USD/run · nessuna azione reale

NON SOLO LA CHAT

Cosa guardiamo

- ① configurazione effettiva
- ② tool e agenti invocati
- ③ numero di chiamate e retry
- ④ input / cached / output
- ⑤ durata e costo per run
- ⑥ fatti e policy della risposta

La tabella che impedisce conclusioni premature

Compilare solo con run realmente osservati.

VARIANTE	QUALITÀ	CALL	INPUT / OUTPUT	LATENZA	COSTO
GPT-5 / GOOD	DA MISURARE	DA MISURARE	DA MISURARE	DA MISURARE	DA MISURARE
GPT-6 Sol / GOOD	DA MISURARE	DA MISURARE	DA MISURARE	DA MISURARE	DA MISURARE
GOOD ridondante	DA MISURARE	DA MISURARE	DA MISURARE	DA MISURARE	DA MISURARE

MOCK non è evidenza di qualità o latenza modello

Dato mancante ≠ zero

Costo stimato ≠ fattura

Una run ≠ benchmark

Sette modi per spendere meno senza “tagliare qualità”

Ottimizza il percorso, non soltanto il prezzo del modello.

01

Recupera dati con tool mirati

non copiare il catalogo

02

Compatta la history

ma conserva i fatti necessari

03

Stabilizza il prefisso

e misura la cache

04

Contratto di output

forma e dettaglio espliciti

05

Limita call e retry

con errori visibili

06

Route per task

Luna/Sol/Astra dopo eval

07

Misura costo per esito

non solo per token

Prima: correttezza e sicurezza. Poi: costo.



IL CICLO

**Osserva → ipotizza → cambia una variabile → verifica →
conserva**

QUALITÀ

prima

LATENZA

scomposta

COSTO

per esito

Qual è la prima evidenza che manca nel vostro sistema?

Domande